

소규모 산업 결함 검출을 위한 생성형 AI 증강 효과

Effects of Generative AI Augmentation for Small-Scale Industrial Defect Detection

요약

산업 제품의 결함을 자동으로 찾아내는 작업은 학습에 사용할 수 있는 결함 이미지가 매우 적다는 구조적 어려움을 안고 있다. 본 연구는 클래스당 20장 수준의 소규모 결함 데이터에서 두 가지 데이터 증강 방식, 즉 이미지의 회전과 색상 변환 등을 적용하는 전통 증강과 대규모 멀티모달 모델을 활용하여 새로운 결함 이미지를 만들어내는 생성형 AI 증강의 효과를 비교하였다. 동일한 학습 조건에서 전통 증강만 적용한 경우는 원본 대비 오히려 성능이 떨어졌으나, 생성형 AI 증강을 적용한 경우는 성능이 향상되었다. 두 방식을 함께 사용한 결함 조건에서는 단독 적용 대비 큰 폭의 성능 향상이 관찰되었으며, 이 효과는 검출 모델 계열을 달리한 6개 대표 모델에서 일관되게 재현되었다. 본 연구는 소규모 산업 결함 검출에서 생성형 AI 증강이 단독으로도 유효하며, 전통 증강과 결합할 때 그 효과가 더욱 커진다는 점을 실험적으로 보인다.

1. 서론

산업 제품의 결함을 자동으로 검출하는 기술은 제조 공정의 품질 관리에서 중요한 역할을 한다. 그중에서도 결함의 위치와 모양을 픽셀 단위로 식별하는 instance segmentation 기법은 결함의 크기와 형태를 정량적으로 다룰 수 있게 한다는 점에서 활용 가치가 높다 [1, 2].

문제는 학습에 쓸 결함 이미지가 매우 부족하다는 점이다. 실제 생산 현장에서 불량률이 발생하는 빈도 자체가 낮고, 결함의 경계를 일일이 표시하는 라벨링 작업은 시간과 비용이 많이 든다. 산업 검사 분야의 대표적인 공개 데이터셋인 VISION-Datasets [3]가 클래스당 수십 장 수준의 학습 데이터를 표준으로 삼고 있다는 사실은 이러한 현실을 반영한다. 데이터가 적은 만큼, 한정된 이미지로부터 얼마나 효과적으로 학습 신호를 만들어 내느냐가 성능을 좌우하게 된다. 이러한 부족을 메우는 일반적인 방법이 데이터 증강이다. 데이터 증강은 크게 두 갈래로 나뉜다. 전통 증강은 이미지를 뒤집거나 회전시키고 밝기와 색상을 바꾸는 식으로 새로운 학습 이미지를 만들어 내는 방식이다. 계산 비용이 거의 들지 않고 구현이 단순해 오랜 기간 표준처럼 쓰여 왔지만, 만들어 내는 이미지가 결국 원본의 변형에 머문다는 한계가 있다. 다른 한 갈래는 최근 등장한 생성형 AI 증강이다. 대규모 멀티모달 모델을 사용해 원본에 없던 새로운 결함 모양과 배경 조합을 만들어 낼 수 있다는 것이 특징이다. 다만 생성된 이미지가 실제 결함처럼 자연스러운지, 라벨이 정확한지를 사람이 직접 확인해야 한다는 비용이 따른다 [4].

소규모 산업 결함 데이터에서 두 증강 방식이 각각 어떻게 작동하는지, 그리고 둘을 함께 썼을 때 어떤 변화가 일어나는지를 동일한 조건에서 직접 비교한 연구는 아직 충분하지 않다. 본 연구는 이 공백을 채우고자 한다. 먼저 두 방식의 단독 효과를 비교하고, 이어 두 방식을 결합했을 때의 효과를 분석한 뒤, 결과가 특정 모델에 국한된 현상이 아닌지 검증하기 위해


검출 모델 계열을 달리한 6개 대표 모델로 실험을 확장하였다.

본 논문의 기여는 다음과 같다. 첫째, 소규모 결함 데이터에서 전통 증강을 단독으로 적용하면 오히려 성능이 떨어질 수 있음을 보인다. 둘째, 생성형 AI 증강이 원본 대비 성능 향상을 가져올 수 있음을 확인한다. 셋째, 두 증강 방식을 함께 적용할 때 단독 적용 대비 더 큰 향상이 관찰됨을 정량적으로 제시한다. 넷째, 이러한 효과가 검출 모델 계열에 무관하게 재현됨을 확인한다.

2. 방법

2.1 데이터셋

VISION-Datasets [3]가 제공하는 14개 산업 카테고리 중에서, 픽셀 단위 라벨이 존재하고 결함 경계가 비교적 뚜렷한 세 종류를 선정하여 통합 데이터셋을 구성하였다. 선정된 결함은 주조 개재물(casting inclusions), 콘솔 오염(console dirty), 목재 이물질(wood impurities)이다. 학습용 원본 이미지는 클래스당 20장씩 총 60장으로 제한하였고, 검증용 이미지 82장은 모든 실험 조건에서 동일하게 사용하였다.



원본 이미지에서 결함을 제거 후
다른 이미지의 결함을 참고해서 결함 이미지 생성

그림 1. 원본 이미지에 생성형 AI 증강을 적용한 예시
(좌: 주조 개재물, 중: 콘솔 오염, 우: 목재 이물질)




그림 2. 실험 파이프라인

2.2 생성형 AI 증강 절차

생성형 AI 증강은 두 단계로 진행된다. 먼저 원본 이미지에서 결함 부분을 제거하여 깨끗한 배경을 만든다. 그다음 다른 원본 이미지에 나타난 결함 형태를 참고하여, 새로운 위치와 모양으로 결함을 합성한 이미지를 생성한다. 이렇게 만들어진 이미지에 대해서는 사람이 직접 결함 영역을 라벨링하고 한 차례 더 검수하여 학습 데이터로서의 정확성을 확보하였다. 생성에는 Gemini 2.0 [4]을 사용하였다. 증강 결과의 예시는 그림 1과 같다.

2.3 증강 조건 설계

본 연구는 네 가지 학습 조건을 비교하였다. 원본 조건은 클래스당 원본 20장만으로 학습한다. 전통 증강 조건은 원본에 Albumentations [10] 기반 변형 이미지 125장을 추가한다. 생성형 AI 증강 조건은 원본에 생성된 결함 이미지 125장을 추가한다. 결함 조건은 원본 20장과 생성형 AI 증강 125장을 합한 클래스당 145장을 기준 구성으로 두고, 그 위에 전통 증강을 추가로 결합하는 조건이다. 전통 증강의 분량은 기준 구성과 동일한 145장을 1배로 정의하고, 1배에서 10배까지 단계적으로 늘려 가며 어느 지점에서 가장 좋은 성능이 나오는지 탐색하였다.

2.4 학습 환경

조건 간 차이가 오직 데이터 구성에서만 발생하도록 학습 설정은 모델별로 통일하였다. Detectron2 계열 모델은 ResNet-50 [11] 백본과 COCO [9] 사전학습 가중치를 공통으로 사용하였고, mmdetection 계열 모델은 해당 프레임워크의 기본 설정을 따랐다. 학습률은 데이터량 변화에도 학습 강도가 동등하게 유지되도록 반복 횟수 기반의 cosine annealing 방식을 적용하였다. 평가 지표는 객체 검출 분야의 표준 지표인 mAP를 사용하였다.

3. 실험 및 결과

3.1 [실험 1] 전통 증강과 생성형 AI 증강 정확도 비교

먼저 두 증강 방식을 같은 분량(클래스당 125장)으로 적용하여 단독 효과를 비교하였다. 결과는 표 1에 제시한 바와 같이 두 방식이 정반대 방향으로 작동함이 나타났다. 전통 증강은 원본 대비 오히려 성능을 떨어뜨렸고, 생성형 AI 증강은 원본 대비 성능을 향상시켰다. 클래스별로 살펴보면 주조 개재물, 콘솔 오염, 목재 이물질 세 클래스 모두에서 동일한 경향이 관찰

되었다.

같은 분량의 데이터를 추가했음에도 효과가 반대로 나타났다는 사실은, 소규모 결함 조건에서 증강 데이터의 양보다 그 출처가 더 중요할 수 있음을 의미한다. 원본 20장이 담고 있는 시각적 패턴은 본질적으로 한정되어 있기 때문에, 이를 픽셀 수준에서 변형하는 것만으로는 모델이 새롭게 배울 정보가 제한적일 수밖에 없다. 오히려 한정된 패턴을 반복적으로 학습하면서 과적합으로 이어질 가능성이 있다. 반면 생성형 AI 증강은 원본에 없던 새로운 결함 형태와 배경 조합을 만들어 내므로, 모델이 학습할 수 있는 시각 패턴의 폭 자체를 넓힌다.

표 1. 모델·클래스별 증강에 따른 mAP 정확도 결과

모델	클래스	원본	전통 증강	생성형 AI증강
Mask R-CNN	주조 개재물	12.4	10.28	14.1
	콘솔 오염	4.8	3.71	6.5
	목재 이물질	13.7	11.63	16.0
Cascade Mask R-CNN	주조 개재물	12.5	11.44	12.9
	콘솔 오염	7.9	6.88	8.7
	목재 이물질	13.3	12.76	13.8

3.2 [실험 2] 생성형 AI 및 전통 증강 결합 실험

생성형 AI 증강이 원본 대비 향상을 제공한다는 관찰을 바탕으로, 원본 20장과 생성형 AI 증강 125장을 합한 클래스당 145장을 기준 구성으로 두고, 그 위에 전통 증강을 추가로 결합하는 조건을 설계하였다. 전통 증강의 분량은 이 기준 구성과 동일한 145장을 1배로 정의하고, 1배에서 10배까지 단계적으로 늘려 가며 성능 변화를 측정하였다.

그림 3은 전통 증강 배수에 따른 mAP 변화를 보여준다. 분량이 어느 지점까지는 늘어날수록 성능도 함께 향상되었으나 일정 수준을 넘어서면 다시 감소하는 양상이 관찰되었다. 본 실험 설정에서는 8배 지점에서 최대 성능이 나타났으며, Cascade Mask R-CNN의 경우 원본 대비 약 +5 mAP의 향상을 달성하였다.

이 결과는 두 증강 방식이 서로 보완적으로 작동함을 의미한다. 생성형 AI 증강이 결함의 의미 수준 다양성을 넓히는 한편, 전통 증강은 그 위에서 픽셀 수준의 미세한 변형을 더해 학습 신호의 폭을 두텁게 하는 역할을 한다. 다만 전통 증강 분량이 지나치게 커




그림 3. 생성형AI증강과 전통증강 N배 결합 결과(mAP)

지면 모델이 다시 원본 분포 쪽으로 끌려가 과적합이 발생하는 것으로 해석되며, 이러한 균형이 본 실험에서는 8배 부근에서 형성되었다.

3.3 [실험 3] 다양한 모델에서의 일반화 검증

앞선 결과가 특정 모델 구조에서만 나타나는 현상은 아닌지 확인하기 위해, 검출 모델을 2단계 CNN, 1단계 CNN, 트랜스포머 세 계열로 나누어 각 계열의 대표 모델을 두 개씩, 총 6개 모델에 동일한 결합 조건(전통 증강 8배)을 적용하였다. 사용한 모델은 2단계 CNN 계열로 Mask R-CNN [1]과 Cascade Mask R-CNN [2], 1단계 CNN 계열로 SOLOv2 [7]와 RTMDet-Ins [8], 트랜스포머 계열로 MaskDINO [5]와 Mask2Former [6]이다. 각 모델의 원본 조건과 결합 조건의 mAP 비교 결과는 그림 4에 정리하였다.

결과적으로 모든 계열에서 결합 조건이 원본 조건보다 높은 성능을 기록하였다. 2단계 CNN 계열은 절대 성능과 향상 폭이 모두 안정적이었고, 1단계 CNN 계열에서도 원본 대비 향상이 분명하게 관찰되었다. 트랜스포머 계열은 절대 성능 자체가 매우 낮은 영역에 머물렀는데, 이는 트랜스포머 계열이 학습에 더 많은 데이터를 요구하는 특성을 갖고 있어 클래스당 20장 수준의 조건에서 충분한 수렴에 이르지 못한 결과로 해석된다. 그럼에도 결합 조건이 원본 조건보다 나은 성능을 보이는 방향성은 동일하게 유지되었다.

이상의 관찰은 제안 증강 조합의 효과가 특정 모델 구조에 국한되지 않고, 검출 모델 계열 전반에서 경향적으로 재현됨을 보여 준다.

4. 토의 및 결론

본 연구는 소규모 산업 결함 검출에서 생성형 AI 증강이 단독으로도 유효하며, 전통 증강과 결합할 때 그 효과가 더욱 커진다는 점을 실험적으로 확인하였다.

연구의 핵심 관찰은 두 가지로 요약된다. 첫째, 같은 분량의 증강 데이터라도 그 출처에 따라 성능에 미치는 영향이 달라지며, 원본의 시각 패턴 범위를 벗어나는 의미 수준의 다양성이 소규모 조건에서 특히 중요한 역할을 한다는 점이다. 둘째, 두 증강 방식은 경쟁 관계가 아니라 보완 관계에 있다는 점이다. 생성형 AI 증강이 결함의 다양성을 확보하면, 전통 증강은 그 위에 적당한 분량까지 추가될 때 성능을 더욱 끌어올린다.

본 연구의 한계는 다음과 같다. 결과는 단일 seed 기준으로 보고되었으며, 실험에 사용된 결함 클래스가 세 종류로 제한되어 있다. 또한 트랜스포머 계열 모델의 절대 성능이 낮은 구간에 머물렀다는 점은 추가 실험을 통해 보완할 필요가 있다. 한편 생성형 AI 증강




그림 4. 모델별 원본 및 결합증강 비교(mAP)

은 효과적이지만 생성 이미지의 품질 검수와 라벨링에 수작업 비용이 수반된다는 점은 실제 산업 현장 도입 시 고려해야 할 요소이다. 향후 연구에서는 결합 클래스의 확대, 다중 seed 기반의 통계적 검증, 모델 계열별 학습 설정의 개별 최적화, 그리고 생성·검수 과정의 자동화를 통해 본 연구의 결과를 보다 폭넓게 검증할 계획이다.

참고문헌

- [1] K. He, G. Gkioxari, P. Dollár, and R. Girshick, "Mask R-CNN," in Proc. ICCV, 2017, pp. 2961–2969.
- [2] Z. Cai and N. Vasconcelos, "Cascade R-CNN: Delving into high quality object detection," in Proc. CVPR, 2018, pp. 6154–6162.
- [3] H. Bai, S. Mou, T. Likhomanenko, R. G. Cinbis, O. Tuzel, P. Huang, J. Shan, J. Shi, and M. Cao, "VISION datasets: A benchmark for vision-based industrial inspection," arXiv:2306.07890, 2023.
- [4] Gemini Team Google, "Gemini: A family of highly capable multimodal models," arXiv:2312.11805, 2023.
- [5] F. Li, H. Zhang, H. Xu, S. Liu, L. Zhang, L. M. Ni, and H.-Y. Shum, "Mask DINO: Towards a unified transformer-based framework for object detection and segmentation," in Proc. CVPR, 2023, pp. 3041–3050.
- [6] B. Cheng, I. Misra, A. G. Schwing, A. Kirillov, and R. Girdhar, "Masked-attention mask transformer for universal image segmentation," in Proc. CVPR, 2022, pp. 1290–1299.
- [7] X. Wang, R. Zhang, T. Kong, L. Li, and C. Shen, "SOLOv2: Dynamic and fast instance segmentation," in Proc. NeurIPS, vol. 33, 2020, pp. 17721–17732.
- [8] C. Lyu, W. Zhang, H. Huang, Y. Zhou, Y. Wang, Y. Liu, S. Zhang, and K. Chen, "RTMDet: An empirical study of designing real-time object detectors," arXiv:2212.07784, 2022.
- [9] T.-Y. Lin, M. Maire, S. Belongie, J. Hays, P. Perona, D. Ramanan, P. Dollár, and C. L. Zitnick, "Microsoft COCO: Common objects in context," in Proc. ECCV, 2014, pp. 740–755.
- [10] A. Buslaev, V. I. Iglovikov, E. Khvedchenya, A. Parinov, M. Druzhinin, and A. A. Kalinin, "Albumentations: Fast and flexible image augmentations," Information, vol. 11, no. 2, p. 125, 2020.
- [11] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in Proc. CVPR, 2016, pp. 770–778.